

Cahier des Charges Fonctionnel



Table des Matières

1. Introduction
2. Présentation Générale
3. Recueil et Analyse des Besoins
4. Exigences Fonctionnelles
5. Exigences Non-Fonctionnelles
6. Interfaces et Intégrations
7. Contraintes Techniques et Organisationnelles
8. Risques
9. Plan de Validation et Critères d'Acceptation
10. Annexes
11. Schéma d'Architecture Applicative
12. Détails Techniques Précis
13. Planning Financier et Calendrier
14. Charte Graphique et Ergonomie

1. Introduction

Contexte du Projet

Le gérant du cinéma New is always better souhaite automatiser la sélection des films à projeter en s'appuyant sur un outil décisionnel. Actuellement, la sélection repose sur une veille des nouveautés et une participation à des festivals (Cannes, Deauville) qui mobilise intuition et expérience. Face à la lourdeur de cette méthode, le gérant envisage de recourir à l'intelligence artificielle pour prédire la fréquentation des nouvelles sorties dès leur première semaine.

Le cinéma adopte une politique unique : il ne diffuse que les nouveautés lors de leur première semaine, renouvelées chaque mercredi. Avec deux salles (capacités respectives de 120 et 80 spectateurs), la programmation hebdomadaire se base sur une estimation du potentiel d'audience, calculée à partir d'une règle : le cinéma peut espérer attirer 1/2000ème du trafic national, ajusté en estimant une audience quotidienne (division par 7).

Objectifs

- Prédire le nombre d'entrées d'un film avant sa sortie grâce à un algorithme de régression.
- Optimiser la programmation en sélectionnant le film au plus fort potentiel pour la salle 1 et le second pour la salle 2.
- Maximiser les recettes en s'assurant que les films programmés correspondent à la capacité des salles.
- Automatiser la collecte des données (scraping) et le processus de prédiction via une application web/mobile simple d'utilisation.
- Intégrer l'ensemble des composants dans une architecture microservices afin de garantir scalabilité et maintenabilité.

Portée du Projet

- Développement d'un modèle de machine learning pour prédire l'audience hebdomadaire d'un film, basé sur diverses sources (Allociné, IMDb, Jpbox, etc.) et un feature engineering précis.
- Création d'un outil décisionnel accessible via une application web.
- Automatisation du scraping et de l'entraînement du modèle, orchestrée via Airflow.
- Mise en place d'une architecture microservices (API de prédiction via FastAPI, bases de données transactionnelle, gestion des expérimentations ML via MLflow/Azure ML) et déploiement avec Docker sur Azure.
- Application de la méthodologie agile (sprints, rôles rotatifs).

Parties Prenantes

- Client/Gérant du cinéma : Décideur de la programmation.

- Équipe de développement IA : 4 développeurs (rôles alternés de Scrum Master, Product Owner et développeurs).
 - Le Boss / Responsable ESN : Supervise l'avancement du projet.
 - Utilisateurs finaux : Gérant du cinéma (dashboard) et clients (consultation de la programmation).
-

2. Présentation Générale

Description du Projet

Le projet vise à développer un outil décisionnel reposant sur l'intelligence artificielle pour prédire la fréquentation des films à leur sortie. En appliquant la règle du 1/2000ème aux entrées nationales et en ajustant en audience quotidienne, le système sélectionne automatiquement les films à projeter en fonction de leur potentiel et des capacités des salles.

Historique et Justification

- Méthode actuelle : Veille des nouveautés, participation aux festivals, décisions basées sur l'intuition.
- Problématique : Processus chronophage et difficile à scaler.
- Justification : Automatiser la collecte et l'analyse des données pour maximiser le chiffre d'affaires.

Enjeux et Défis

- Technique : Algorithme de régression performant, feature engineering, scraping multi-sources sans target leaking.
 - Organisationnel : Application de la méthode agile sur 4 sprints et coordination des rôles.
 - Opérationnel : Automatisation complète de la chaîne (scraping, prédiction, affichage) pour respecter les délais hebdomadaires.
 - Économique : Maximisation des recettes tout en contrôlant les coûts fixes.
-

3. Recueil et Analyse des Besoins

Identification des Utilisateurs

- Principal utilisateur : Le gérant du cinéma.
- Utilisateurs secondaires : Équipe technique pour la maintenance.
- Intervenants externes : Fournisseurs de données.

Scénarios d'Utilisation

- Consultation du Dashboard : Le gérant consulte l'application web/mobile pour voir les prédictions et la sélection des films.
- Automatisation du Scraping et Prédiction : Processus automatisé récupérant les données (Scrapy) et déclenchant l'entraînement/prédiction (Airflow/Cronjob).
- Révision des Prédictions : Comparaison des prédictions initiales (jeudi) avec les mises à jour (lundi).
- Analyse Post-Diffusion : Comparaison entre les prédictions et les chiffres réels, mise à jour des indicateurs.
- Consultation de la Programmation : Les clients consultent la programmation hebdomadaire sur le site.

Contraintes et Exigences Spécifiques

- Prédictions réalisées le plus tôt possible (initiale jeudi, affinée lundi).
 - Intégration de données multiples et fiables (Allociné, IMDb, Jpbox) en évitant le target leaking.
 - Prise en compte des sorties internationales et locales.
 - Processus de scraping et d'entraînement entièrement automatisés.
 - Outil simple d'utilisation, accessible sans compétences spécifiques en informatique ou IA.
-

4. Exigences Fonctionnelles

Fonctionnalités Principales

- Estimation du Potentiel d'Audience : Calcul basé sur la règle du 1/2000ème et conversion en audience quotidienne.
- Sélection des Films : Attribution du film avec la meilleure estimation à la salle 1 (120 places) et le second à la salle 2 (80 places). Possibilité de diffusion dans les deux salles en cas de dépassement.
- Calcul Financier : Recette hebdomadaire (entrées estimées x 10 €) déduite des frais fixes de 4900 €.
- Collecte Automatisée de Données : Service de scraping pour collecter des données de sources multiples.
- Modèle de Machine Learning : Développement et entraînement d'un algorithme de régression (gestion via MLflow et Azure ML).
- Dashboard de Visualisation : Affichage du top 10 des sorties, répartition des films par salle, indicateurs financiers, historique des prédictions et comparaisons.
- API de Machine Learning : Exposition du modèle via FastAPI pour consommation par le dashboard.
- Automatisation de l'Entraînement et du Scraping : Orchestration avec Airflow.

Cas d'Utilisation et Flux Fonctionnels

- Flux de données :
 - Le service de scraping collecte les données et les stocke dans la base de données analytique.
 - Le modèle ML consomme ces données, effectue les prédictions et expose les résultats via l'API FastAPI.
 - Le dashboard (Django) interroge l'API et affiche les informations.
 - L'orchestrateur déclenche les processus automatisés dès que de nouvelles données sont disponibles.
-

5. Exigences Non-Fonctionnelles

Performance et Fiabilité

- Temps de Réponse : L'API FastAPI doit répondre rapidement.
- Disponibilité : Système scalable et opérationnel, notamment lors des pics liés aux sorties de films.
- Mise à Jour des Prédictions : Prédiction initiale rapide (jeudi) puis version affinée (mardi).

Sécurité

- Authentification et Autorisation : Accès sécurisé au dashboard via système de login/mot de passe ou tokens.
- Protection des Données : Chiffrement et sécurisation des échanges entre composants (API, bases de données).

Ergonomie et Design

- Interface Simple et Intuitive : Conception en Django/Tailwind pour une navigation conviviale.
- Accessibilité : Dashboard responsive accessible sur ordinateur et mobile.
- Clarté de l'Information : Présentation synthétique et graphique des indicateurs clés.

Compatibilité et Interopérabilité

- Stack Technique : Python (Django, FastAPI), Scrapy, Airflow, Docker.
 - Intégration Cloud : Déploiement sur Azure via containerisation Docker.
 - Communication Inter-Service : Échanges via HTTP/REST et format JSON (CSV pour certains échanges si nécessaire).
-

6. Interfaces et Intégrations

Interfaces Utilisateur

- Application Web (Dashboard) : Développée en Django/Tailwind pour la consultation des prédictions, films sélectionnés et indicateurs financiers.
- Interface Mobile : Version responsive accessible depuis un navigateur mobile.

Interfaces avec d'Autres Systèmes

- API Machine Learning (FastAPI) : Exposition des prédictions pour consommation par le dashboard.
- Service de Scraping (Scrapy) : Récupération de données depuis Allociné, IMDb, Jpbox.
- Orchestrateur de Tâches (Airflow) : Automatisation du scraping et déclenchement de l'entraînement.
- Systèmes de Gestion de Projets : Synchronisation entre Jira et GitHub pour la gestion agile.
- Outils de Suivi d'Expériences ML : Intégration de MLflow via Azure ML.

Formats d'Échange et Protocoles

- Communication : Protocole HTTP/REST.
 - Formats de Données : Échanges en JSON.
 - Conteneurisation : Docker pour une intégration homogène et déploiement sur Azure.
-

7. Contraintes Techniques et Organisationnelles

Contraintes Techniques

- Technologies :
 - Langage : Python
 - Frameworks : Django, FastAPI, Tailwind
 - Outils de scraping : Scrapy
 - Orchestration : Airflow
 - Machine Learning : MLflow, Azure Machine Learning
 - Bases de données : MySQL (transactionnelle) et Azure Storage (analytique)
 - Conteneurisation : Docker
 - Infrastructure Cloud : Azure
- Architecture : Microservices pour garantir indépendance et scalabilité.
- Intégration Continue : Synchronisation entre Jira et GitHub pour une gestion agile des branches/features.

Contraintes Organisationnelles

- Méthodologie Agile : Projet réparti sur 4 semaines en 4 sprints avec rôles rotatifs (Scrum Master, Product Owner, développeurs).
- Planning et Livrables :
 - Sprint 0 : Cahier des charges fonctionnel, schéma d'architecture, mise en place de l'environnement (2 jours)
 - Sprint 1 : Mise en place de la base de données analytique (7 jours)
 - Sprint 2 : Développement du modèle de machine learning (7 jours)
 - Sprint 3 : Première version de l'outil (6 jours)
 - Sprint 4 : Présentation finale de l'outil (1 jour)
- Coordination : Réunions hebdomadaire avec le client et suivi des tâches via Jira.
- Budget : Estimation détaillée des coûts mensuels des ressources Azure.

Environnement de Développement et de Déploiement

- Développement : Environnements locaux basés sur Docker, IDE VScode et outils de versioning (GitHub).
- Production : Déploiement sur Azure avec conteneurs Docker, bases de données sécurisées.

8. Plan de Validation et Critères d'Acceptation

Méthodologie de Test

- Tests d'Intégration : Vérification de la communication entre les services (Django ↔ FastAPI, Scrapy ↔ BDD, etc.).
- Tests de Performance : Validation des temps de réponse de l'API et rapidité des processus automatisés.
- Tests Utilisateurs : Évaluation de l'ergonomie et de la clarté du dashboard par le gérant.
- Validation des Prédictions : Comparaison entre les résultats prédits et les chiffres réels post-diffusion.

Critères d'Acceptation

- Fonctionnalité de Prédiction : Le modèle doit fournir une estimation d'audience avec une marge d'erreur acceptable.

- Interface Utilisateur : Le dashboard doit présenter clairement les films sélectionnés, le top 10 des sorties, et l'estimation du chiffre d'affaires.
- Automatisation : Les processus de scraping et d'entraînement/prédiction doivent être déclenchés aux dates prévues (prédiction initiale jeudi, version affinée mardi).
- Sécurité : L'accès à l'outil doit être sécurisé conformément aux normes en vigueur.
- Documentation : La documentation technique et fonctionnelle doit être validée par le client.

Suivi et Évolutions

- MLflow & Azure ML : Suivi continu des expérimentations et ajustement du modèle.
- Revues de Sprint : Présentation des avancées au client à la fin de chaque sprint.
- Feedback Utilisateur : Collecte et analyse des retours pour améliorer l'outil dans les itérations futures.
- Système de réservation : Possibilité pour le client du cinéma de réserver une séance selon la disponibilité.

9. Annexes

Documents de Référence


- Brief complet du projet "Prédire la popularité d'un film - Simplon - DEV IA Roubaix 2025".
- Documentation technique sur Django, FastAPI, Scrapy, MLflow, Azure Machine Learning.
- Ressources sur l'industrie cinématographique (nombre de cinémas, prix moyen, dates de sortie et avant-premières).
- Cours d'OpenClassrooms sur la rédaction d'un cahier des charges fonctionnel.

Tableau des Risques

Type	Risque	Impact	Mesures d'atténuation / Remarques
Technique	Qualité et Disponibilité des Données : Risque de blocage anti-scraping ou d'obtenir des données incomplètes/biaisées depuis les sources (Allociné, IMDb, Jpbox).	Prédictions inexactes et sélection de films non optimale, avec un impact direct sur le chiffre d'affaires.	- Diversifier les sources - Mettre en place un monitoring pour suivre la qualité des données extraites. - Prévoir des mécanismes de relance et de récupération en cas d'échec lors du scraping.
Technique	Performance et Fiabilité du Modèle de Machine Learning : Difficulté à modéliser avec précision la complexité des comportements d'audience.	Faible précision des prédictions, mauvaise affectation des films aux salles, pertes financières.	- Réaliser des tests préliminaires sur des jeux de données historiques. - Définir des KPI clairs (MAE, RMSE, R²) et des marges d'erreur acceptables.
Organisationnel	Surcharge de Travail et Polyvalence : Une seule équipe en charge de tous les aspects (IA, scraping, développement web) peut être surchargée et risquer une répartition floue des responsabilités.	Risques de retards, baisse de la qualité ou de la spécialisation dans certaines tâches.	- Définir clairement les rôles et responsabilités de chacun. - Mettre en place des rituels agiles réguliers pour assurer une bonne coordination. - Prévoir éventuellement l'intervention ponctuelle d'experts externes pour les domaines spécialisés.

Externe	Évolution de l'Industrie Cinématographique : Changements imprévus dans les tendances de sortie ou dans les critères de sélection des films par les distributeurs.	Le modèle peut devenir désynchronisé par rapport aux pratiques du marché, menant à des prédictions obsolètes.	- Intégrer des indicateurs de marché et effectuer une veille régulière. - Mettre à jour fréquemment les sources de données. - Ajuster le modèle en fonction des nouvelles tendances et variables qui impactent la fréquentation des films.
Financier	Dépassement des Coûts Cloud : Les coûts liés à l'utilisation des ressources Azure pourraient dépasser les prévisions si l'utilisation s'accroît ou si des inefficacités apparaissent.	Risque de dépassement budgétaire pouvant impacter la viabilité financière du projet.	- Suivi en temps réel de la facturation Azure via des outils de monitoring. - Optimiser l'utilisation des ressources en fonction des besoins réels. - Définir des seuils d'alerte budgétaire pour détecter rapidement toute dérive.
Juridique / Sécurité	Non-conformité Réglementaire et Risques Sécuritaires : Non-respect des règles RGPD, des CGU des sources de données ou des normes de sécurité.	Sanctions légales, perte de confiance des utilisateurs, et atteinte à la réputation de l'entreprise.	- Assurer une veille juridique en collaboration avec un expert en conformité. - Mettre en place des mesures de sécurité robustes (authentification forte, chiffrement des échanges, audits réguliers).
Qualité des Prédictions	Dérive du Modèle (Model Drift) : Les comportements d'audience évoluant ou l'apparition de nouvelles variables pourraient fausser les prédictions.	Mésestimation des audiences, mauvaise programmation, et perte de revenus.	- Mettre en place un suivi continu des performances du modèle. - Prévoir des réentraînements réguliers en fonction des données réelles observées. - Intégrer un système de retour d'expérience pour ajuster le modèle en continu.

10. Schéma d'Architecture Applicative



11. Détails Techniques Précis

Spécifications détaillées du modèle de machine learning (architecture, algorithmes envisagés, critères de performance, etc.), choix entre Airflow, liste des sources de données exactes (URLs, API, modalités d'accès).

À compléter au fur et à mesure de l'avancement du projet.

12. Planning Financier et Calendrier

Estimation détaillée des coûts mensuels pour les ressources Azure, planning de développement par sprint avec dates précises et jalons intermédiaires.

Planning financier :


Microsoft Azure Estimate						
Votre estimation						
Service category	Service type	Custom name	Region	Description	Estimated monthly cost	Estimated upfront cost
Bases de données	Azure Database for MySQL		France Central	Déploiement de Serveur flexible, Niveau Burstable, 1 B1MS (1 vCores) x 730 Heures, Stockage de 10 Go avec redondance ZRS, 0 IOPS supplémentaires, 10Go Stockage de sauvegarde supplémentaire avec LRS	€15,00	€0,00
Conteneurs	Azure Container Registry		France Central	Basic Niveau, 1 registre x 30 jours, 0 Go Espace de stockage supplémentaire, Génération de conteneur – 100 processeurs x 1 Secondes – Type de transfert de sortie Internet, transfert de données sortantes 5 Go à partir de France Centre routé via Réseau Microsoft mondial	€4,63	€0,00
Web	API Management		France Central	Service de gestion des API, niveau Consommation,	€0,00	€0,00

				appels 10 000		
IA + Machine Learning	Machine Learning Studio (classic)		West Europe	API web Classic : 0 transactions, 1 heures	€1,85	€0,00
Calcul	Azure Container Instances		France Central	2 groupe(s) de conteneurs x 10 seconde(s), Linux système d'exploitation, À l'utilisation, 1 GB mémoire, 2 processeur(s) virtuel(s)	€0,00	€0,00
Support			Support		€0,00	€0,00
			Licensing Program	Microsoft Customer Agreement (MCA)		
			Billing Account			
			Billing Profile			
			Total		€21,48	€0,00
Disclaimer						
All prices shown are in Euro Zone – Euro (€) EUR. This is a summary estimate, not a quote. For up to date pricing information please visit https://azure.microsoft.com/pricing/calculator/						
This estimate was created at 4/2/2025 2:10:11 PM UTC.						


Calendrier:

	Description	Dates	Review
Sprint 1			
Sprint 2			
Sprint 3			
Sprint 4			


13. Charte Graphique et Ergonomie




Page d'accueil (accessible par les clients pour voir la programmation des salles)




Page de Login




Page de programmation



Liste de films choisis par le modèle ML



Page de statistiques pour le gérant



Historique des prédictions